

xR — Recuperação Esperada sob Pressão: um modelo logístico calibrado com alvo espacialmente restrito para análise tática no futebol

Primeiro Autor

Filiação
Endereço da Instituição
e-mail

Segundo Autor

Filiação
Endereço da Instituição
e-mail

Terceiro Autor

Filiação
Endereço da Instituição
e-mail

RESUMO

Avaliar se um jogador deveria ou não perder a posse sob pressão é central na análise tática do futebol. Propomos o *xR* (Recuperação Esperada), a probabilidade calibrada de a equipe que pressiona recuperar a bola, estimada a partir do StatsBomb-360. Mostramos empiricamente que a **definição do alvo** — e não a arquitetura do modelo — é a principal alavanca preditiva: restringir o sucesso no tempo e no espaço (recuperar em até 5 s e a até 5 m) eleva a AUC de 0,59 para 0,70, enquanto GNN, CNN e Set Transformer, *sob o alvo padrão de recuperação em até 10 s*, estacionam em $\approx 0,59$. Uma regressão logística **leve e calibrada** (ECE 0,003) iguala modelos pesados e habilita usos agregados: análise de adversário, treino, *scouting* e revisão pós-jogo (*xR* vs. realizado). Delimitamos honestamente o escopo: *ratings* individuais de jogador têm confiabilidade $\approx 0,09$, inadequados para veredito individual.

PALAVRAS CHAVE. Análise esportiva, Aprendizado de máquina, Modelos calibrados.

Tópicos: EST – Estatística; ADA – Análise de Dados; Aplicações em Esporte.

ABSTRACT

Assessing whether a player should or should not lose possession under pressure is central to tactical football analysis. We propose *xR* (Expected Recovery), the calibrated probability that the pressing team regains the ball, estimated from StatsBomb-360 data. We show empirically that the **target definition** — not the model architecture — is the main predictive lever: constraining success in time and space (recovery within 5 s and 5 m) raises AUC from 0.59 to 0.70, while GNN, CNN and Set Transformer plateau at ≈ 0.59 *under the standard 10 s recovery target*. A **light, calibrated** logistic regression (ECE 0.003) matches heavy models and enables aggregate uses: opponent analysis, training, scouting and post-match review (*xR* vs. actual). We honestly delimit scope: individual player ratings have reliability ≈ 0.09 , unfit for individual verdicts.

KEYWORDS. Sports analytics, Machine learning, Calibrated models.

Paper topics: Statistics; Data Analysis; Sports Applications.

1. Introdução

O *pressing* — a pressão coordenada sobre o portador da bola e seus arredores — tornou-se um pilar tático do futebol de elite. Quantificar sua eficácia, e em particular avaliar **se um jogador deveria ou não perder a posse** em um contexto específico, é de interesse direto para comissões técnicas, no treino, na análise de adversário e no *scouting*. A literatura recente ataca o problema com dados de eventos e, mais recentemente, dados posicionais [Robberechts, 2019; Merckx et al., 2021; Lee et al., 2025], mas duas lacunas persistem: (i) os modelos preditivos estacionam em desempenho modesto ($AUC \approx 0,60$), sem uma explicação clara do porquê; e (ii) os *ratings* individuais de jogador são apresentados de forma anedótica, sem auditoria de confiabilidade.

Este trabalho propõe o **xR (Recuperação Esperada)**: a probabilidade calibrada de a equipe que pressiona recuperar a bola dentro de uma janela curta, vista do lado do portador como o risco de *perder* a posse. A partir de uma extensa jornada experimental sobre o StatsBomb Open Data (incluindo a UEFA Euro 2020 e a Copa do Mundo FIFA 2022), nossas contribuições são:

1. **Achado central (o alvo define o sinal).** Mostramos, por ablação, que a informatividade da geometria dos jogadores depende de *como* se define o sucesso do pressing. Restringir o desfecho no tempo *e* no espaço (recuperar em ≤ 5 s e a ≤ 5 m do ponto de pressão) eleva a AUC de 0,59 para 0,70 com as *mesmas* variáveis, enquanto arquiteturas profundas (GNN, CNN, Set Transformer) não ultrapassam $\approx 0,59$ sob o alvo padrão de recuperação em ≤ 10 s.
2. **Um modelo proposto leve e calibrado.** Uma regressão logística sobre atributos geométricos, com o alvo espacialmente restrito, iguala modelos pesados na qualidade probabilística (ECE 0,003) e é interpretável — adequada para uso por analistas e comissão técnica.
3. **Delimitação honesta de escopo.** Quantificamos a confiabilidade dos *ratings* individuais de jogador ($\approx 0,09$ mesmo com 91.692 pressões), mostrando que o modelo é uma ferramenta *agregada* de apoio à decisão, não um juiz de jogadas ou de jogadores.

2. Trabalhos relacionados

A valoração de pressing foi formalizada por Robberechts [2019] (VPEP) num arcabouço de risco–recompensa, estendido por Merckx et al. [2021] com detecção baseada em regras e modelagem de desfechos. Lee et al. [2025] (exPress) propõem um modelo XGBoost sobre dados de eventos e StatsBomb-360 para estimar a probabilidade de recuperação, com aplicação a ajustes posicionais contrafactuais; reportam AUC de 0,607 (recuperação em 5 s) e até 0,712 sob um critério de “2 ações”. Modelos de superfície como o SoccerMap [Fernández e Bornn, 2020] usam CNNs sobre representações espaciais. A geometria do pressing foi estudada por Andrienko et al. [2017] e, via pose 3D, por Gu e Kanagasabai [2024]; a contrapressão por Bauer e Anzer [2021].

Em valoração de ações e posse, VAEP [Decroos et al., 2019] e *Expected Threat* [Singh, 2019] atribuem valor a ações a partir do contexto, e modelos de *Expected Possession Value* foram desenvolvidos no basquete [Cervone et al., 2016] e em outros esportes coletivos. A importância de probabilidades *calibradas* para uso prático é discutida por Niculescu-Mizil e Caruana [2005]. Nosso trabalho difere por (i) isolar o efeito da definição do alvo sobre o sinal geométrico e (ii) auditar a confiabilidade dos *ratings* individuais, em vez de apresentá-los sem validação.

3. Conceitos: modelos e métricas

Para tornar o texto autocontido, esta seção descreve sucintamente os modelos preditivos e as métricas e técnicas de avaliação empregados no estudo.

3.1. Regressão logística

Modelo linear que mapeia uma combinação linear dos atributos em probabilidade pela função logística. É leve e interpretável (cada coeficiente é um *log-odds*) e, por otimizar a *log-loss*, tende a produzir probabilidades bem calibradas. É o modelo que adotamos como proposta final do xR.

3.2. Gradient boosting (GBT/XGBoost)

Ensemble de árvores de decisão criadas em sequência, cada uma corrigindo os resíduos das anteriores. Captura interações não lineares automaticamente e trata valores faltantes de forma nativa. Usamo-lo (XGBoost) como referência de capacidade; é mais pesado e menos interpretável que a logística.

3.3. Modelos de conjunto: DeepSets e Set Transformer

Operam sobre o *conjunto* de adversários de forma invariante à ordem. O DeepSets transforma cada ponto e agrega por média/máximo; o Set Transformer usa *autoatenção* para modelar interações entre os pontos sem definir arestas. Servem de *baselines* geométricos.

3.4. Redes neurais em grafo (GNN)

Representam a cena como um grafo (jogadores são nós; relações são arestas). Cada nó atualiza seu estado agregando “mensagens” dos vizinhos (*message passing*); após algumas camadas, um *pooling* global resume o grafo para a predição. Capturam interações relacionais sem reduzir a geometria 2D a um rótulo.

3.5. Redes convolucionais (CNN)

Operam sobre uma imagem (*raster*); filtros convolucionais detectam padrões locais com invariância a translação. Aqui a cena é rasterizada em um *heatmap* das posições e a CNN lê a densidade e a textura espacial.

3.6. CNN multicanal (estilo SoccerMap)

Variante em que a imagem tem *vários canais* — p. ex. adversários, apoios e campos de distância e ângulo ao gol — em vez de um único. Cada canal codifica um aspecto do contexto espacial, permitindo à rede combinar entidades e referências de campo [Fernández e Bornn, 2020].

3.7. Stacking

Combinação de modelos em que um *meta-modelo* (aqui, uma logística) é treinado sobre as probabilidades previstas pelos modelos-base, buscando um sinal superior ao de cada um isolado.

3.8. Diagramas de Voronoi

Particionam o campo em células — uma por jogador —, onde cada ponto pertence ao jogador mais próximo. Células adjacentes indicam vizinhança espacial; usamos essa adjacência (`scipy.spatial.Voronoi`) para selecionar os marcadores imediatos do portador e definir arestas do grafo, sem raio arbitrário.

3.9. Discriminação: ROC-AUC e PR-AUC

A **ROC-AUC** é a probabilidade de o modelo atribuir *score* maior a um positivo do que a um negativo; por ser estatística de *ranqueamento*, é **invariante à prevalência** e adequada para **comparar alvos**. A **PR-AUC** (área sob a curva precisão–*recall*) tem como piso a *base rate* e cresce com mais positivos; logo **não** é comparável entre alvos, apenas *dentro* de um mesmo alvo.

3.10. Base rate (taxa-base)

Proporção de positivos do alvo — a frequência com que o evento ocorre (p. ex. $\approx 29\%$ no `y_10s`, $6,9\%$ no `y_5s_5m`). É o referencial do acaso: com base $6,9\%$, prever sempre “negativo” já acerta 93% , tornando a acurácia enganosa em alvos raros; é também o denominador do *lift*.

3.11. Calibração (*Brier*, *ECE*) e *lift*

A calibração mede se as probabilidades previstas batem com as frequências observadas (“20% previsto $\Rightarrow$ 20% observado”). O *Brier score* é o erro quadrático médio da probabilidade; o *ECE* (*Expected Calibration Error*) é o desvio médio entre risco previsto e observado por faixa. É a calibração que habilita o uso *agregado* (valor esperado). O *lift* (curva de ganho) traduz a discriminação em valor de triagem: densidade de positivos no topo de risco dividida pela *base rate*.

3.12. Intervalo de confiança por *bootstrap*

Técnica de reamostragem: reamostra-se o conjunto de teste com reposição muitas vezes, recalculando a métrica a cada vez; os percentis 2,5% e 97,5% formam o IC 95%. Usamos um *bootstrap pareado* para o IC da diferença de AUC entre alvos, separando ganho real de variância amostral.

3.13. Ablação de atributos

Avalia a contribuição de cada grupo de atributos treinando o mesmo modelo sobre sub-conjuntos: cada bloco isolado, o conjunto *sem* um bloco e o conjunto completo. A *contribuição marginal* de um bloco é a variação de desempenho ao incluí-lo — p. ex. $AUC(ALL) - AUC(\text{sem geometria})$ mede quanto a configuração de jogadores acrescenta.

4. Dados, alvo e atributos

Dados. Usamos o StatsBomb Open Data [StatsBomb, 2021] com *freeze frames* 360 (posições dos jogadores visíveis no instante do evento). O conjunto reúne 326 partidas com 360 (UEFA Euro 2020 e 2024, Copa do Mundo FIFA 2022, Euro Feminina, Copa do Mundo Feminina e Bundesliga 2023/24), totalizando **91.692 eventos de pressão**. A unidade de análise é cada evento Pressure.

Alvo. “Perder a bola” (do portador) equivale a “recuperar a bola” (da equipe que pressiona): uma recuperação subsequente da mesma equipe (Ball Recovery, Interception ou Duel vencido), casada por `merge_asof` dentro de uma janela. Definimos cinco alvos: `y_5s` e `y_10s` (recuperar em $\leq 5/10$ s); `y_2act` (em até 2 ações); e os alvos **especialmente restritos** `y_5s_5m` e `y_5s_9m` (recuperar em ≤ 5 s e a $\leq 5/9$ m do ponto de pressão).

Atributos. Reorientamos os adversários em torno do portador (origem; frente = $+x$) e derivamos: geometria de configuração de jogadores (contagens em 5/10/15 m, distância ao adversário mais próximo, cobertura angular, maior ângulo livre, centróide e dispersão, vizinhança de Voronoi); posição em campo (x , y , distância ao gol, terço); e contexto (minuto, duração). Excluímos atributos endógenos (desarme/falta/bloqueio concorrentes), que vazam o desfecho. Atributos de Voronoi usam a adjacência de células de `scipy.spatial.Voronoi`.

5. Evolução experimental

Esta seção segue a trajetória do projeto: da validação estatística do *input* ao achado do alvo. Avaliamos **deliberadamente** um amplo espectro de metodologias e arquiteturas — de *base-lines* unidimensionais (regras, k -means) a modelos de conjunto (DeepSets, Set Transformer), redes em grafo (GNN) e redes convolucionais (CNN) — *justamente para verificar se alguma metodologia ou arquitetura se sobressairia de forma significativa sobre as demais*. Como se verá, isso **não ocorreu**: todas convergiram para um mesmo teto de desempenho, o que deslocou o foco da pesquisa da *arquitetura* do modelo para a *definição do alvo*.

5.1. Validação estatística do *input*

Antes de modelar, submetemos cada atributo a uma bateria de testes (Mann-Whitney/quadrado com correção de Benjamini-Hochberg, VIF, Wald e razão de verossimilhança). A maioria dos atributos geométricos apresenta efeito pequeno (Cohen’s $d \approx 0,08-0,13$); os únicos efeitos fortes são endógenos e foram removidos. Esse resultado já antecipa o teto preditivo da geometria instantânea sob o alvo padrão.

5.2. Representações de entrada e modelos de geometria

Todos os modelos descrevem a *mesma* cena — os adversários reorientados em torno do portador (origem; frente = $+x$) — mas a consomem por representações distintas (Tabela 1):

- **Tabular** (regressão logística e *gradient boosting*): o vetor de 18 atributos da Seção 4 — 12 de geometria de jogadores, 4 de posição da bola e 2 de contexto. As árvores tratam valores faltantes do 360 nativamente; a logística usa padronização.
- **Conjunto de pontos** (DeepSets, Set Transformer e GNN): cada adversário vira um nó com atributos $(x/30, y/30, dist/30)$, até $K = 14$ nós com máscara de *padding*. O DeepSets agrega os nós por média/máximo; o Set Transformer usa autoatenção (sem arestas explícitas); a GNN (GCN denso) propaga mensagens sobre uma **adjacência** entre nós — vizinhos a ≤ 10 m ou, na variante, o subgrafo de Voronoi — seguida de *pooling* média/máximo e MLP.
- **Imagem raster** (CNN): um *heatmap* centrado no portador (grade 48×48 , extensão ± 30 m, *bumps* gaussianos com $\sigma \approx 3$). Na variante multicanal (estilo SoccerMap), usam-se canais separados para adversários, apoios e campos de distância e ângulo ao gol.

A **seleção por Voronoi** substitui o critério “adversários a ≤ 30 m” pelos adversários cuja célula de Voronoi é adjacente à do portador (o anel imediato de marcadores), com as arestas dadas pelo subgrafo de Voronoi — uma seleção *adaptativa*, sem raio arbitrário. Todos os modelos preveem o *mesmo* alvo y_{10s} , com *split* estratificado treino/validação/teste, aumento por reflexão (modelos espaciais) e *early stopping* pela AUC de validação (neurais) ou parada interna (GBT).

Tabela 1: Representações de entrada por família de modelo (mesma cena, mesmo alvo y_{10s}).

Modelo	Representação	Atributos de entrada
Logística / GBT	Tabular (18 dim.)	geometria (12) + posição (4) + contexto (2)
DeepSets / Set Transf.	Conjunto $\leq 14 \times 3$ (+ máscara)	$(x, y, dist)$ por adversário
GNN (GCN denso)	Grafo (nós + adjacência)	nós $(x, y, dist)$; arestas ≤ 10 m ou Voronoi
CNN <i>raster</i>	Imagem $1-4 \times 48 \times 48$	<i>heatmap</i> : adversários (+ apoio, dist., ângulo)

Apesar da diversidade de representações e capacidades, **todos convergem para AUC $\approx 0,55-0,59$** sob o alvo y_{10s} (Tabela 2): baselines 1D (regras, *k*-means), modelos de conjunto, GNN e CNN. **A arquitetura não move o teto** — o que motiva a revisão da definição do alvo na seção seguinte.

Tabela 2: Modelos da geometria do pressing (alvo y_{10s} , recuperação em ≤ 10 s).

Modelo	AUC (teste)
Regressão logística (contexto)	0,541
Regras 1D / <i>k</i> -means 1D	0,557 / 0,551
DeepSets / GCN / Set Transformer	0,581 / 0,579 / 0,572
GNN (C++, seleção por Voronoi)	0,554
CNN <i>raster</i> (1 canal)	0,589
CNN multicanal (estilo SoccerMap)	0,593
<i>Stacking</i> (contexto + CNN)	0,592

5.3. O pivô do alvo (achado central)

Fixando o modelo (*gradient boosting*) e variando apenas a definição de sucesso, a AUC salta de 0,591 (y_{10s}) para **0,702** (y_{5s_5m}), com as mesmas variáveis (Figura 1). O alvo espacialmente restrito remove “positivos ruidosos” (recuperações tardias e distantes, pouco atribuíveis àquela pressão) e torna a configuração local genuinamente preditiva.




Figura 1: Efeito da definição do alvo sobre a AUC, com modelo e atributos fixos. Restringir o desfecho no tempo e no espaço é a maior alavanca preditiva.

5.4. Ablação: de onde vem o sinal

Aplicamos a ablação de atributos (Seção 3.13) aos blocos geometria de jogadores (GEOM), posição em campo (POS) e contexto (CTX). A Figura 2 mostra que, sob y_{5s_5m} , a geometria isolada atinge 0,679 (maior bloco) e contribui +0,071 marginalmente sobre POS+CTX — contra +0,053 sob y_{10s} . Ou seja, o alvo restrito não só eleva a AUC: torna a geometria *mais* informativa.




Figura 2: Ablação por bloco de atributos. A geometria de jogadores é o maior contribuinte e ganha importância sob o alvo espacialmente restrito.

5.5. Controle: a base rate não explica o ganho

Como y_{5s_5m} tem *base rate* bem menor que y_{10s} (6,9% vs. 29%), é preciso descartar que sua AUC maior seja um artefato da prevalência. Conduzimos dois controles sobre o

modelo proposto (logística). (i) **Igualando a *base rate***: reduzimos por amostragem os positivos do y_{10s} até sua base atingir 6,9% e reajustamos o modelo; a AUC permanece **0,573** ($\pm 0,007$ em 25 repetições), praticamente idêntica à AUC com base cheia (0,571). Baixar a *base rate* não eleva a AUC — coerente com a invariância da ROC-AUC à prevalência. (ii) **Significância do gap**: um *bootstrap* pareado (1.000 reamostragens do mesmo conjunto de teste) da diferença $AUC(y_{5s_5m}) - AUC(y_{10s})$ resulta em $+0,113$, com **IC 95%** $[0,100; 0,124]$, bem acima de zero. O ganho do alvo espacialmente restrito é, portanto, **real e estatisticamente robusto**, e não um efeito da *base rate* ou da variância amostral.

5.6. Generalização entre competições

Para descartar vazamento entre eventos da mesma partida, comparamos o *split* aleatório, o *held-out* da Copa do Mundo 2022 inteira e o *GroupKFold* por partida (alvo y_{10s}): 0,591 / 0,590 / 0,590, respectivamente. As estimativas são **estáveis** — não há inflação por vazamento.

6. O modelo proposto: xR logístico calibrado

6.1. Logística vs. *gradient boosting*

A Tabela 3 compara, sob y_{5s_5m} , uma regressão logística leve e o *gradient boosting* (XGBoost). Para o uso pretendido — probabilidade/valor esperado em agregado — a logística é **tão confiável quanto**, e até marginalmente *melhor calibrada* (ECE 0,002 vs. 0,003; Brier praticamente idêntico). O ganho do GBT aparece apenas na discriminação fina (AUC $+0,02$, *lift* $2,33\times$ vs. $2,17\times$), justamente o uso menos confiável. Adotamos a logística como o **modelo proposto**, por ser leve, interpretável e igualmente calibrada.

Tabela 3: Logística vs. *gradient boosting* no alvo y_{5s_5m} (base 6,9%).

Modelo	AUC	PR-AUC	Brier	ECE	Prec. top-10%	<i>Lift</i>	Recall top-10%
Logística (proposto)	0,683	0,124	0,063	0,0015	0,151	$2,17\times$	0,217
GBT (XGBoost)	0,702	0,136	0,062	0,0033	0,162	$2,33\times$	0,233

6.2. Calibração e curva de ganho

A Figura 3 mostra que o xR é bem calibrado: quando o modelo prevê risco de 20%, observa-se $\approx 20\%$. Essa propriedade legitima o xR como um *expected model*, na mesma linhagem do xG. A Figura 4 traduz a discriminação em valor operacional: revisando as 10% jogadas de maior risco, encontra-se densidade de perdas $2,3\times$ maior que o acaso, capturando $\approx 23\%$ de todas as perdas — útil para **triagem de vídeo**, não para alarme automático.

6.3. Limites de escopo: confiabilidade de *ratings* individuais

Agregando o desempenho *esperado* vs. *realizado* por jogador, a confiabilidade *split-half* do *rating* de retenção é de apenas **0,091** (Spearman, 613 jogadores, 91.692 pressões) — mesmo com a correção de Spearman-Brown ($\approx 0,17$), muito abaixo do patamar usável ($\geq 0,5-0,7$). A Tabela 4 sintetiza: o modelo é apto para uso agregado e calibrado, **não** para veredito individual de jogada ou de jogador. Esta é uma diferença metodológica central frente a trabalhos que reportam *rankings* individuais sem auditoria.

6.4. Contexto do evento: o tipo de gatilho adiciona sinal?

Uma análise complementar caracterizou *gatilhos de pressão* pelo passe adversário que precede a pressão (recuo, passe lateral, passe perto da linha lateral, cobrança de lateral) e pela situação do portador (isolado, sem companheiro a ≤ 15 m). Avaliamos, na Euro 2020 (13.999 pressões), se o tipo de gatilho **acrescenta sinal** ao modelo logístico, com um baseline *honesto* (todas as pressões) e o alvo y_{5s_5m} .




Figura 3: Calibração (y_{5s_5m}): risco previsto vs. frequência observada.




Figura 4: Curva de ganho: *lift* e *recall* acumulado por fração revisada.

Tabela 4: Aptidão por uso. Calibração habilita o agregado; baixa confiabilidade impede o individual.

Uso pretendido	Evidência	Apto?
Probabilidade / valor esperado (agregado)	ECE 0,003; Brier 0,062	Sim
Triagem de vídeo / priorização	<i>lift</i> $2,3\times$ (top-10%)	Sim (apoio)
Alerta de jogada isolada	$\approx 84\%$ falso alarme	Não
Rating individual de jogador	confiabilidade 0,09	Não

Descritivamente, os gatilhos diferem bastante (Tabela 5): pressionar após um *recuo* recupera muito menos (razão 0,30 sobre o baseline), enquanto após *cobrança de lateral* recupera mais (1,73). **Como sinal preditivo, porém, o tipo de gatilho quase nada acrescenta:** incluir os indicadores de gatilho na logística altera a AUC de 0,702 para 0,694 sob y_{5s_5m} ($\Delta = -0,008$) e de 0,599 para 0,608 sob y_{5s} ($+0,009$). Ou seja, sob o alvo estrito a **geometria já captura o sinal**, e a categoria do gatilho é *descritiva/explicativa*, não incrementalmente preditiva — coerente com a tese de que o ganho vem do alvo e da configuração espacial, não de mais contexto categórico.

Tabela 5: Recuperação por gatilho na Euro 2020 (alvo y_{5s_5m} ; baseline = todas as pressões, 6,1%).

Gatilho	n	Recuperação	Razão
Cobrança de lateral	601	10,5%	1,73
Perto da linha lateral	1.487	6,3%	1,04
Passe lateral	2.455	4,6%	0,76
Jogador isolado	1.794	4,2%	0,69
Recuo (passe para trás)	891	1,8%	0,30

6.5. Contrapressão: a vantagem persiste sob o alvo estrito?

Outra análise complementar isolou a *contrapressão* — pressão até 5 s após a própria equipe perder a bola — e comparou sua eficácia à da pressão regular no terço ofensivo. Sob o

alvo frouxo (recuperação em ≤ 10 s), a contrapressão recupera mais (29,5% vs. 24,0%; $p < 0,001$), confirmando a literatura. Reavaliamos sob o alvo estrito y_{-5s_5m} : na comparação *bruta* a diferença deixa de ser significativa (6,7% vs. 6,1%; $p = 0,14$), **mas** isso é um artefato de confundimento por zona — a contrapressão concentra-se no terço ofensivo, onde a recuperação imediata-e-local é mais rara. Controlando a zona numa logística, a contrapressão volta a ter efeito positivo e significativo (*odds ratio* **1,36**; IC 95% [1,18; 1,56]). **Conclusão:** o benefício da contrapressão é real mesmo no alvo estrito, porém menor e *dependente de zona* — mais um caso em que a definição do alvo e o contexto espacial determinam a leitura.

7. Aplicação prática

A Figura 7 resume o fluxo de uso do xR por uma equipe de analistas e comissão técnica. Após cada jogo, o modelo pontua toda pressão; os xR sobem de jogada para **zona, gatilho e time**, onde a leitura é confiável. As aplicações naturais são: (i) **análise de adversário** (onde e como o próximo oponente recupera/perde a bola, alimentando o plano de pressing); (ii) **treino** (desenho de gatilhos a partir de padrões esperados vs. realizados); (iii) **scouting** (métricas agregadas com amostra grande, cruzadas com observação); e (iv) **revisão pós-jogo**, comparando o xR esperado com o que de fato aconteceu e priorizando os cliques de maior discrepância. Em todas as etapas, o modelo *sugere*; o analista contextualiza com vídeo; a comissão técnica decide.

Exemplos concretos. Para ilustrar com rigor, treinamos a logística em 36 jogos da Euro 2020 e aplicamos o xR a 15 jogos de *teste* que o modelo nunca viu (taxa-base 5,5%). Em todos os casos, a *predição* é o xR de cada pressão — a probabilidade de a equipe que pressiona recuperar a bola em ≤ 5 s e a ≤ 5 m.

Análise de adversário (pré-jogo). À pergunta “Vamos enfrentar a Itália — em que zona a nossa pressão tem maior chance de recuperar a bola?”, o modelo pontua as 591 pressões sofridas pela Itália e agrega o xR por zona: a pressão rende mais no **terço defensivo** dela (xR médio 8,4%) do que no de ataque (3,8%) — onde priorizar o gatilho. O padrão se repete contra Suíça (7,7% vs. 3,5%) e Espanha (9,4% vs. 4,3%).

Revisão pós-jogo (xR esperado vs. realizado, Figura 5). À pergunta “No jogo França×Suíça, a pressão da Suíça rendeu o que se esperava?”, o modelo prevê o xR das 220 pressões da Suíça e os soma: **13,9 recuperações esperadas** contra **11 realizadas** (−2,9) — a equipe pressionou bem, mas converteu *abaixo* do esperado. As pressões mais instrutivas para o vídeo são as de **xR alto que falharam**: situações em que a geometria *favorecia* a recuperação (xR 18–21%) e, ainda assim, a bola não foi retomada. São, por definição, as melhores oportunidades perdidas — revisá-las mostra *o que deu errado apesar de um bom posicionamento*, e por isso viram os primeiros *clipes* de revisão.

Triagem de vídeo / treino. À pergunta “Temos pouco tempo — o que revisar primeiro?”, ordenam-se todas as pressões pelo xR. Como o xR *concentra* as recuperações, revisar apenas a fração de maior xR cobre a maior parte delas com pouco vídeo: as **10% de maior xR** têm densidade de recuperação **2,9×** a taxa-base e contêm **28%** de todas as recuperações do conjunto; subindo para 20% do vídeo, captura-se 44%. É a tradução direta do poder de *ranqueamento* do modelo em economia de análise. As Figuras 5 e 6 trazem o passo a passo da revisão pós-jogo em dois exemplos e dois protocolos de validação (36 jogos de treino/15 de teste e 47/4), ilustrando que a história não depende do tamanho do *held-out*.

“No jogo France x Switzerland, a pressão do Switzerland rendeu o esperado?”




Figura 5: Passo a passo de um exemplo real (**36 jogos de treino, 15 de teste held-out**): da pergunta da comissão à resposta do xR, na revisão pós-jogo de França x Suíça.

“No jogo Italy x England, a pressão do England rendeu o esperado?”




Figura 6: O mesmo passo a passo com mais dados de treino (**47 jogos de treino, 4 de teste held-out**): revisão pós-jogo de Itália x Inglaterra. A leitura é a mesma, ilustrando que o fluxo não depende do tamanho do held-out.




Figura 7: Fluxo de aplicação do xR e delimitação de escopo (verde: uso válido e calibrado; vermelho: fora do escopo).

8. Conclusão

Apresentamos o xR, um modelo logístico calibrado de recuperação esperada sob pressão. O resultado mais importante é metodológico: a **definição do alvo** — e não a sofisticação do modelo — determina a previsibilidade e o quanto a geometria dos jogadores carrega sinal; um alvo espacialmente restrito eleva a AUC de 0,59 para 0,70 e torna a geometria mais informativa. Um modelo leve e interpretável basta para o uso que importa na ponta: análise de adversário, treino, *scouting* e revisão pós-jogo, sempre em agregado e com probabilidades calibradas. Delimitamos o escopo com evidência: *ratings* individuais de jogador não são confiáveis no volume de dados de torneios. Como trabalho futuro, destacam-se a ponderação por valor (xT/VAEP) do risco de perda, formulações de sobrevivência para o horizonte temporal, e a validação externa dos *ratings* com dados de temporada completa.

Referências

- Andrienko, G., Andrienko, N., Budziak, G., Dykes, J., Fuchs, G., von Landesberger, T., e Weber, H. (2017). Visual analysis of pressure in football. *Data Mining and Knowledge Discovery*, 31 (6):1793–1839.
- Bauer, P. e Anzer, G. (2021). Data-driven detection of counterpressing in professional football. *Data Mining and Knowledge Discovery*, 35(5):2009–2049.
- Cervone, D., D’Amour, A., Bornn, L., e Goldsberry, K. (2016). A multiresolution stochastic process model for predicting basketball possession outcomes. In *Journal of the American Statistical Association*.
- Decroos, T., Bransen, L., Van Haaren, J., e Davis, J. (2019). Actions speak louder than goals: Valuing player actions in soccer. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- Fernández, J. e Bornn, L. (2020). SoccerMap: A deep learning architecture for visually-interpretable analysis in soccer. In *ECML PKDD 2020, Applied Data Science Track*. Springer.
- Gu, C. e Kanagasabai, V. D. S. (2024). Player pressure map: A novel representation of pressure in soccer for evaluating player performance in different game contexts. In *MIT Sloan Sports Analytics Conference*.
- Lee, M., Jo, G., Hong, M., Bauer, P., e Ko, S.-K. (2025). exPress: Contextual valuation of individual players within pressing situations in soccer. In *MIT Sloan Sports Analytics Conference*.
- Merckx, S., Robberechts, P., Euvrard, Y., e Davis, J. (2021). Measuring the effectiveness of pressing in soccer. In *Machine Learning and Data Mining for Sports Analytics (MLSA), 8th International Workshop*.
- Niculescu-Mizil, A. e Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*.
- Robberechts, P. (2019). Valuing the art of pressing. In *StatsBomb Innovation in Football Conference*.
- Singh, K. (2019). Introducing expected threat (xT). <https://karun.in/blog/expected-threat.html>.
- StatsBomb (2021). StatsBomb open data and StatsBomb 360. <https://statsbomb.com/>.